

Plan

Introduktion

Øvelsernes formål og form + lidt om eksamen

NB om uge 8

R + Rstudio og Rprojekt mappen

Hjemmeside og nye filer

Tidyverse

I dag i R....:

Indlæse og behandle data (dplyr)

Subsette data

Omforme data (adjacencymatricer) (Matrix)

Netværksobjekter (igraph)

Netværksdatamanipulation (tidygraph)

Netværksvisualisering (ggraph)

Hvad I kan om 7 uger:

- Finde og håndtere netværksdata (relationel data).



- Bearbejde (netværks-) data i R




- Konstruere netværksobjekter



igraph – The network analysis package

- Beregne netværksmål på forskellige niveauer

- Netværksniveau
- Gruppeniveau
- Aktørniveau



- Fortolke og forstå netværksmål i forhold til sæt spørgsmål

- Afrapportere og visualisere netværks analyser



- Hvor findes netværk?
- Hvor er netværkets grænse?
- Hvem/hvad er med? Hvad er relationen?
- Hvad betyder en forbindelse, har den en vægt?, en retning?
- Hvordan beskriver vi et netværk bedst i forhold til de spørgsmål vi ønsker at svare på? Hvilke mål er nødvendige og relevante og ikke mindst hvilke er IKKE?
- Hvilke visuelle greb udtrykker bedst de pointer og erkendelser, vi vil kommunikere ift en analyse.

Tidyverse



En samling af R pakker, til læsning, behandling og visualisering af data i R.

I dag skal vi snakke lidt om **dplyr**, som er en værktøjskasse til datahåndtering.



Datagrammatik: Verber (funktioner)

- dplyr er en samling funktioner eller verber (*verbs*), som *gør* noget med data. På den måde bliver programmering til et sprog, hvor man kan sige man 'taler med' R.

-

filter()

select()

group_by()

mutate()

rename()

distinct()

summarise()

rowwise()

arrange()

count()

- Generalt er strukturen i en tidyverse kode altid:
- 1. et data-objekt 2. en række verber 3. et nyt ændret data-objet

1. Input data



2. Verber

summarise()

mutate()

select()

filter()

3. Output data



Rækker, kolonner eller grupper

- Man kan inddele de centrale funktioner eller *verber* i dem der gør noget 'på' dataens rækker, kolonner eller behandler det som grupper.


Rækker	Kolonner	Grupper
filter()	select()	summarise()
slice()	mutate()	rowwise()
slice_sample()	relocate()	
arrange()	rename()	group_by()

Hjælpeverber i fx select()

starts_with()	any_of()
ends_with()	all_of()
matches()	
contains()	

Og så 'pipen': %>%

- Ideen er at man sender det, der står til venstre videre mod højre.
- På den måde kan man skrive sin kode som en lang kæde uden at gemme en masse midlertidige objekter undervejs.



Nesting vs piping

Vi har et datasæt **ydat**, hvor vi gerne vil udregne og afrunde korrelationen mellem *rate* og *expression*, inden for forskellige næringsstoffer, men kun for de cases, hvor *bp* er “leucine biosynthesis”, og sidst sortere data efter korrelationsværdien

Old way

vs

dplyr way

```
arrange(  
  mutate(  
    summarize(  
      group_by(  
        filter(ydat, bp=="leucine biosynthesis"),  
        nutrient),  
      r=cor(rate, expression)),  
    r=round(r, 2)),  
  r)
```

**Cognitive
process:**

1. Take the **ydat** dataset, *then*
2. **filter()** for genes in the leucine biosynthesis pathway, *then*
3. **group_by()** the limiting nutrient, *then*
4. **summarize()** to correlate rate and expression, *then*
5. **mutate()** to round *r* to two digits, *then*
6. **arrange()** by rounded correlation coefficients

```
ydat %>%  
  filter(bp=="leucine biosynthesis") %>%  
  group_by(nutrient) %>%  
  summarize(r=cor(rate, expression)) %>%  
  mutate(r=round(r,2)) %>%  
  arrange(r)
```


Tidy Netværk



igraph – The network analysis package

+

tidygraph: dplyr udvidelse til netværksdata:
dvs. dataobjekter med både noder og edges



ggraph: ggplot udvidelse til relationel data:
dvs. dataobjekter med både noder og edges.
Gør det lettere at lave netværksvisualiseringer

